

Dokumentacja specyfikacji wymagań (SRS)

Projekt: Porównawcza analiza opinii użytkowników ChatGPT i Gemini z wykorzystaniem analizy sentymentu i asocjacji słów.

Wersja dokumentu: 1.1

Data: 06.06.2026

Autorzy: Arseniy Vanitskiy, Jakub Jankowski

1. Wprowadzenie

Celem niniejszego dokumentu jest przedstawienie specyfikacji wymagań dla systemu informatycznego wspierającego analizę danych i procesy decyzyjne oparte na algorytmach data science. Projekt obejmuje zaprojektowanie, implementację i dokumentację skryptu analitycznego eksplorującego dane tekstowe, ze szczególnym uwzględnieniem podejścia Reproducible Research. Narzędzie to służy do porównywania recenzji użytkowników dwóch wiodących modeli sztucznej inteligencji: ChatGPT oraz Gemini, co pozwala na identyfikację trendów oraz różnic w odbiorze tych narzędzi.

2. Cele systemu

- Stworzenie działającego skryptu w języku R, który automatycznie analizuje dane tekstowe z plików .csv przy pomocy algorytmów poznanych podczas zajęć.
- Zidentyfikowanie i zbadanie trendów w opiniach użytkowników na temat ChatGPT i Gemini.
- Interpretacja wyników poprzez czytelne wizualizacje graficzne.
- Spełnienie standardów Reproducible Research, zapewniając dostępność kodu i danych w formacie możliwym do bezproblemowego powtórzenia i odtworzenia.
- Wygenerowanie gotowego, interaktywnego raportu HTML z wynikami analizy.

3. Wymagania funkcjonalne

- System musi poprawnie wczytywać dane tekstowe z plików .csv.
- System musi przeprowadzać czyszczenie danych, w tym filtrowanie pustych opinii, odrzucanie opinii poniżej 20 znaków oraz losowanie próby badawczej (20 000 obserwacji).
- System musi wykonywać tokenizację tekstu oraz usuwać tzw. stop words, wykorzystując zarówno wbudowane słowniki języka angielskiego, jak i dedykowaną

listę słów wykluczonych.

- System musi przeprowadzać analizę sentymentu w oparciu o słownik "nrc", badając rozkład ośmiu kategorii emocji oraz porównując ogólny sentyment pozytywny i negatywny.
- System musi identyfikować najczęściej występujące słowa w obu modelach oraz najczęstsze słowa w obrębie konkretnych kategorii sentymentu.
- System musi tworzyć macierz Term-Document Matrix (TDM) do dalszej analizy statystycznej.
- System musi obliczać asocjacje słów na podstawie współczynnika korelacji Pearsona dla zdefiniowanych pojęć (np. "wrong", "answer", "subscription", "understanding") powyżej zadanego progu korelacji.
- System musi generować elementy wizualizacji wyników, takie jak wykresy słupkowe i punktowe, przy użyciu pakietu ggplot2.

4. Wymagania niefunkcjonalne

- Skrypt musi być napisany w całości w języku R i uruchamiać się bez błędów w środowisku RStudio.
- Kod źródłowy musi być czytelnie napisany, zawierać odpowiednie komentarze oraz jasny podział na sekcje.
- System musi zapewniać odpowiednią wydajność, pozwalając na płynne przetwarzanie do kilkudziesięciu tysięcy obserwacji.
- Analiza musi wykorzystywać architekturę modułową, korzystając z pakietów analitycznych takich jak m.in.: dplyr, tidytext, tm, ggplot2 oraz patchwork.
- Cały projekt (kod, dane oraz wygenerowany raport HTML) musi zostać umieszczony w repozytorium GitHub.

5. Interfejsy użytkownika

Wejście:

- Plik danych w formacie .csv zawierający opinie użytkowników.
- Parametry analizy ustawiane w kodzie:
 - liczba analizowanych opinii,
 - próg korelacji dla asocjacji słów,
 - wybór słowa do analizy asocjacji.

Wyjście:

- Wykresy analizy sentymentu (NRC):
 - rozkład emocji,
 - porównanie sentymentu pozytywnego i negatywnego.

- Wykres najczęstszych słów po czyszczeniu danych.
- Wizualizacja asocjacji słów (wykres zależności na podstawie współczynnika korelacji Pearsona).

6. Wymagania dotyczące danych

- Dane wejściowe stanowią zbiór opinii użytkowników zapisanych w pliku CSV.
- Dane tekstowe mogą zawierać opinie w różnych językach, jednak analiza sentymentu opiera się głównie na słownikach języka angielskiego.
- Zbiór danych powinien zawierać kolumnę tekstową z opiniami.
- Dane powinny być oczyszczone z podstawowych błędów (np. brakujące wartości, duplikaty).
- Analiza opiera się na reprezentacji tekstu w postaci macierzy Term-Document Matrix (TDM).
- Do analizy sentymentu wykorzystywane są słowniki dostępne w pakiecie `tidytext` lub `SentimentAnalysis`.
- Analiza asocjacji słów wymaga wystarczającej liczby wystąpień danego słowa w korpusie.
- Parametry analizy (np. próg korelacji, liczba analizowanych dokumentów) are ustawiane w kodzie.
- Skrypt nie obsługuje danych w innych językach ani formatów innych niż CSV.
- Zalecany rozmiar danych: do kilkudziesięciu tysięcy obserwacji (ze względu na wydajność).

7. Słownictwo dokumentacji

- **Sentyment** – emocjonalne nastawienie wyrażone w tekście (pozytywne, negatywne lub neutralne).
- **Tokenizacja** – proces podziału tekstu na pojedyncze słowa (tokeny).
- **Stop words** – często występujące słowa (np. „the”, „and”), które nie niosą istotnej informacji i są usuwane z analizy.
- **Stemming** – proces sprowadzania słów do ich rdzeni (np. „running” → „run”).
- **Term-Document Matrix (TDM)** – macierz przedstawiająca częstość występowania słów w dokumentach.
- **Korelacja Pearsona** – miara zależności liniowej między dwoma zmiennymi (w tym przypadku współwystępowaniem słów).
- **Asocjacje słów** – współwystępowanie słów w dokumentach, wskazujące na ich semantyczne powiązanie.
- **Korpus tekstowy** – zbiór dokumentów tekstowych poddawanych analizie.
- **Wizualizacja danych** – graficzne przedstawienie wyników analizy.

Przypadki użycia (use cases)

Aktor: Użytkownik

- Wczytuje plik CSV zawierający opinie użytkowników.
- Uruchamia skrypt analizy w środowisku R.
- Ustawia parametry analizy.

Aktor: System

- Przetwarza dane tekstowe (tokenizacja, usuwanie stop words, stemming).
- Analizuje sentyment tekstów.
- Generuje wizualizacje sentymentu (wykresy).
- Buduje macierz TDM.
- Oblicza asocjacje słów (korelacje).
- Generuje wykresy asocjacji słów.

Testowe przypadki użycia

- Analiza zbioru opinii o pozytywnym sentymencie – system powinien wykazać przewagę pozytywnych ocen.
- Analiza zbioru opinii o negatywnym sentymencie – system powinien wykazać przewagę negatywnych ocen.
- Analiza asocjacji dla często występującego słowa (np. "wrong", "answer") – system powinien zwrócić powiązane słowa.
- Analiza asocjacji dla rzadkiego słowa – system może nie zwrócić wyników (brak asocjacji).
- Analiza danych zawierających brakujące wartości – system powinien je pominąć lub poprawnie obsłużyć.
- Analiza danych wielojęzycznych – wyniki mogą być częściowo zniekształcone.

Scenariusze użytkownika (user stories)

Scenariusz 1: Wybór modelu AI na podstawie analizy opinii

Jako: Potencjalny użytkownik narzędzi AI

Chcę: Porównać opinie o ChatGPT i Gemini

Aby: Wybrać narzędzie najlepiej dopasowane do potrzeb.

Kryteria akceptacji:

- System umożliwia analizę opinii dla dwóch modeli AI.

- System prezentuje wyniki sentymentu dla ChatGPT i Gemini.
- Użytkownik może porównać poziom pozytywnego i negatywnego sentymentu.
- System umożliwia analizę asocjacji słów dla obu modeli.
- Użytkownik może na podstawie wyników podjąć decyzję o wyborze narzędzia.

Scenariusz 2: Ocena zasadności zmiany narzędzia AI

Jako: Użytkownik korzystający z jednego modelu AI

Chcę: Sprawdzić, czy zmiana z jednego narzędzia (np. Gemini) na inne (np. ChatGPT) ma sens

Aby: Podjąć racjonalną decyzję bez niepotrzebnej zmiany narzędzia.

Kryteria akceptacji:

- System umożliwia analizę opinii dla obu modeli AI.
- System prezentuje porównanie wyników sentymentu.
- System umożliwia analizę asocjacji słów dla obu modeli.
- Użytkownik może zidentyfikować różnice w opiniach użytkowników.
- System wspiera użytkownika w ocenie, czy zmiana narzędzia przyniesie realne korzyści.

Scenariusz 3: Optymalizacja wykorzystania narzędzi AI

Jako: Analityk danych lub użytkownik

Chcę: Zidentyfikować mocne i słabe strony różnych modeli AI (ChatGPT i Gemini)

Aby: Wykorzystywać odpowiednie narzędzie w zależności od konkretnego zadania.

Kryteria akceptacji:

- System umożliwia analizę opinii dla obu modeli AI.
- System prezentuje różnice w sentymencie użytkowników.
- System umożliwia analizę asocjacji słów dla obu modeli.
- Użytkownik może zidentyfikować obszary, w których dany model jest oceniany lepiej lub gorzej.
- System wspiera podejmowanie decyzji dotyczących wyboru narzędzia w zależności od potrzeb.

Scenariusz 4: Analiza opinii użytkowników ChatGPT

Jako: Analityk danych

Chcę: Przeanalizować opinie użytkowników ChatGPT z pliku CSV

Aby: Zrozumieć ogólny sentyment oraz najczęstsze problemy użytkowników.

Kryteria akceptacji:

- Użytkownik może wczytać plik CSV z opiniami.
- Skrypt przetwarza tekst (tokenizacja, stop words, stemming).
- System generuje wykresy sentymentu.
- System wyświetla wyniki w raporcie HTML.
- System umożliwia analizę asocjacji słów.

Scenariusz 5: Analiza opinii użytkowników Gemini

Jako: Analityk danych

Chcę: Przeanalizować opinie użytkowników Gemini

Aby: Zrozumieć ogólny sentyment oraz najczęstsze problemy użytkowników.

Kryteria akceptacji:

- Użytkownik może wczytać plik CSV z opiniami.
- Skrypt przetwarza tekst (tokenizacja, stop words, stemming).
- System generuje wykresy sentymentu.
- System wyświetla wyniki w raporcie HTML.
- System umożliwia analizę asocjacji słów.

